Prevedere il basket: dall'analisi delle sequenze binarie alla stima delle probabilità di vittoria

Francesca Dorigo

Sommario

In questo studio ho analizzato un insieme di stagioni NBA (2014-2018) con l'obiettivo di comprendere la dinamica delle sequenze di gioco e costruire un modello predittivo basato su parametri intrinseci delle squadre. Le azioni offensive sono state modellate come processi binari. Per la fase predittiva ho ipotizzato che ogni squadra possieda una probabilità intrinseca di successo, stimata tramite massimizzazione della verosimiglianza sui dati storici. Ho così ottenuto i parametri e successivamente li ho impiegati per prevedere l'esito delle partite della stagione 2018-2019. Tramite il confronto con un modello nullo di Bernoulli ho visto che i dati presentano autocorrelazioni significative. Il modello predittivo ha ottenuto un'accuratezza del 57.56% sulla stagione di test.

1 Introduzione

In molti sport, come il basket, è possibile modellare l'esito delle singole azioni di gioco come una sequenza di eventi binari (successi e insuccessi). Analizzare queste sequenze permette di studiare la dinamica interna delle partite, individuare schemi ricorrenti e costruire modelli utili per stimare gli esiti di partite future.

In questo report sono presentate le mie analisi su diverse stagioni dell'NBA, con l'obiettivo di verificare l'esistenza di fenomeni di "streaks" o autocorrelazioni nei risultati delle azioni e di costruire un modello predittivo basato su parametri intrinseci alle squadre, calibrato su dati storici, utilizzabile per stimare l'esito di partite non ancora giocate.

2 Dati

I dati utilizzati per quest'analisi provengono dal file *play-by-play* dell'NBA database di Wyatt Walsh[1]. Sono state selezionate le stagioni regolari (regular seasons) comprese tra il 2014-2015 e il 2017-2018 come base per le analisi e la costruzione del modello. La stagione 2018-2019 è stata invece utilizzata come test per il modello sviluppato.

Per realizzare le sequenze binarie sono state selezionate solo le azioni di tipo offensivo, assegnando il valore di 1 (successo) alle azioni che hanno portato a un aumento del punteggio, e il valore di 0 (insuccesso) a quelle che non hanno portato a un aumento.

3 Metodi

3.1 Modello nullo: Bernoulli

Un processo di Bernoulli è una successione di variabili aleatorie binarie indipendenti e identicamente distribuite, con una data probabilità di successo p.
In questa analisi ho utilizzato questo modello per generare sequenze simulate da confrontare con i dati reali.

Ho generato tante sequenze quante quelle presenti nei dati reali con:

- probabilità di successo p pari alla probabilità media empirica osservata nei dati reali
- lunghezze variabili, campionate casualmente nell'intervallo tra la lunghezza minima e quella massima delle sequenze reali, in modo da riflettere la variabilità presente nei dati

Ho preso questo processo come modello nullo e poi condotto successive analisi per verificarne la bontà.

3.2 Autocorrelazione con lag k

L'autocorrelazione con lag k di una sequenza misura quanto una variabile è linearmente correlata con sé stessa, ma spostata di k posizioni.
È un caso particolare della correlazione di Pearson applicata tra la sequenza originale e quella traslata.

La definizione normalizzata dell'autocorrelazione con lag k è data dalla formula:

$$\rho_k = \frac{\sum_{i=0}^{n-k-1}(x_i - \bar{x})(x_{i+k} - \bar{x})}{\sum_{i=0}^{n-k-1}(x_i - \bar{x})^2}$$

dove:

$$\rho_k = corr(X_{0:n-k}, X_{k:n})$$

In questa formula:

- $corr(A, B)$ è il coefficiente di Pearson tra i due vettori A e B
- $X_{0:n-k}$ sono i primi $n-k$ elementi
- $X_{k:n}$ sono gli ultimi $n-k$ elementi, partendo dalla posizione k

La correlazione di Pearson tra due vettori è definita come:

$$corr(A, B) = \frac{cov(A, B)}{\sigma_A \cdot \sigma_B}$$

dove:

- $cov(A, B) =$ covarianza tra A e B
- $\sigma_A, \sigma_B =$ deviazione standard di A e B

[1] Disponibile su Kaggle: NBA Play-by-Play Data

3.3 Log-verosimiglianza

Per stimare le probabilità individuali di vittoria delle squadre ho adottato un approccio basato sulla massimizzazione della verosimiglianza. L'idea alla base del modello è che ogni squadra i possieda una probabilità $p_i \in (0, 1)$ di successo in una singola azione, che dipende dalle caratteristiche intrinseche della squadra. Per ogni coppia di squadre (A, B), la probabilità che A vinca una singola azione contro B è modellata come:

$$P(A \text{ vince contro } B) = p_A \cdot (1 - p_B)$$

dove:

- p_A è la probabilità che la squadra A vinca una singola azione contro qualsiasi altra squadra
- p_B è la probabilità che la squadra B vinca una singola azione contro qualsiasi altra squadra

e simmetricamente per B.

Sotto ipotesi di azioni indipendenti, la probabilità di osservare k successi per A in una sequenza di n azioni è quindi descritta da:

$$P(k; p_A, p_B) \propto (p_A(1 - p_B))^k \cdot (p_B(1 - p_A))^{n-k}$$

La log-verosimiglianza, che rappresenta la probabilità logaritmica di osservare i dati a partire dai parametri del modello, è quindi definita come:

$$logL(p) = \sum_{partite} [k \cdot log(p_A(1 - p_B)) + (n - k) \cdot log(p_B(1 - p_A))]$$

Ho poi massimizzato questa quantità rispetto al vettore delle probabilità intrinseche p con un algoritmo di ottimizzazione numerica (*scipy.optimize.minimize*) sulla funzione negativa della log-verosimiglianza per adattarsi al paradigma di minimizzazione, al fine di trovare i valori di p per cui le azioni osservate tra le squadre risultano più probabili secondo il mio modello.

4 Risultati

4.1 Streaks e breaks

La prima domanda a cui ho cercato di rispondere è stata quella di andare a vedere se esistessero o meno i fenomeni di streaks e breaks all'interno delle partite.
Per fare ciò sono andata a filtrare i dati tenendo solo le azioni offensive, dividendole per squadre e assegnando il valore di 1 (successo) alle azioni che hanno portato a un cambiamento di punteggio, mentre 0 (insuccesso) a quelle che non hanno portato cambiamenti. Poi sono andata a raggruppare per valori successivi queste sequenze binarie, trovando così la lunghezza di streaks (1) e breaks (0). In seguito sono andata a normalizzare il numero di streaks per partita e li ho confrontati con delle opportune sequenze Bernoulli generate come descritto nella sezione 3.1, con i parametri estratti dai dati presenti in tabella 1.

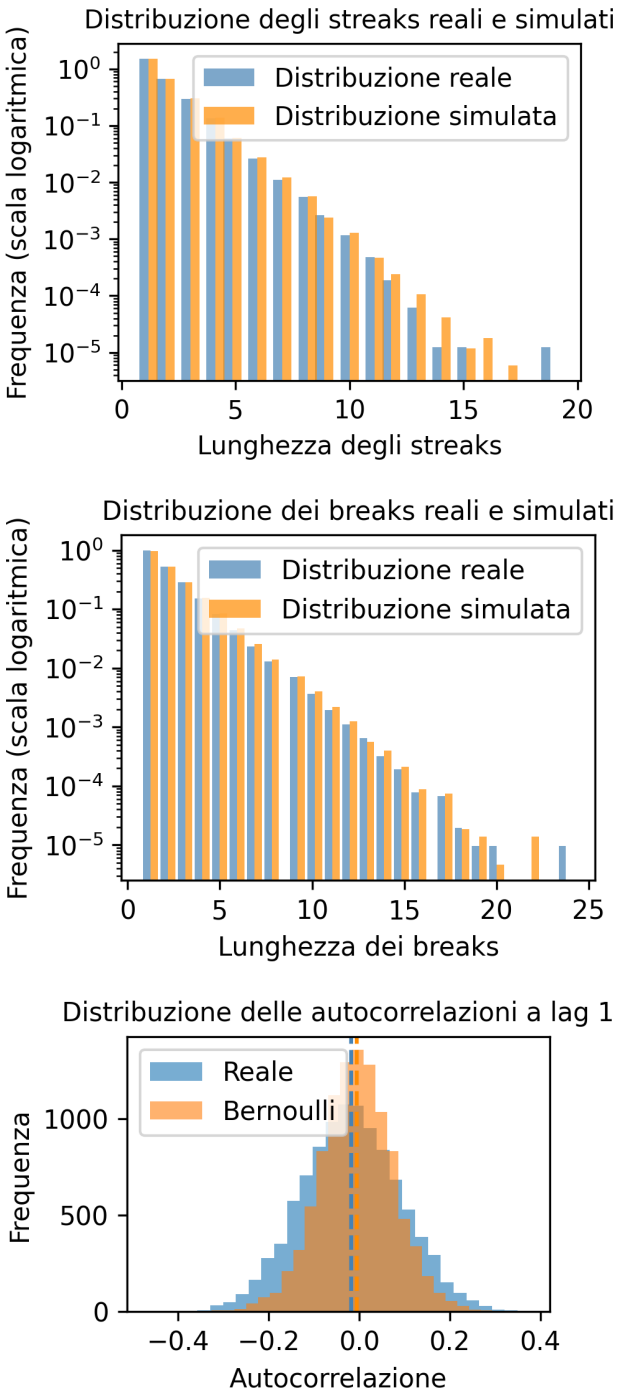


Figura 1: Nei primi due grafici sono rappresentate le distribuzioni delle lunghezze degli streaks di successi (1) e dei breaks di insuccessi (0) per le sequenze reali, in blu, e le sequenze simulate tramite un processo Bernoulli, in arancione. Il grafico è in scala logaritmica per meglio evidenziare le code, e le colonne dell'istogramma sono affiancate anziché sovrapposte per migliore leggibilità. Nel terzo grafico sono rappresentate e confrontate tra loro le distribuzioni a lag 1 delle autocorrelazioni tra le sequenze reali e quelle simulate Bernoulli, le linee tratteggiate centrali rappresentano i rispettivi valori medi.

Negli istogrammi in figura 1, si può chiaramente vedere sia che per gli streaks che per i breaks di lunghezze > 5 la distribuzione reale inizia a distaccarsi da quella di Bernoulli. Per confermare quantitativamente la differenza tra i dati reali e il modello di riferimen-

to (Bernoulli), ho condotto diversi test statistici. Il test di Kolmogorov-Smirnov ha restituito un p-value pari a 0.0018, mentre il test del Chi-quadro ha prodotto un p-value di 0.0009, entrambi indicativi di una significativa divergenza tra le due distribuzioni.
Per analizzare la dipendenza temporale, ho calcolato l'autocorrelazione a lag 1 delle sequenze binarie. I risultati sono stati:
- autocorrelazione media reale (lag 1): –0.0183
- autocorrelazione media Bernoulli (lag 1): –0.0058
Ho poi verificato la significatività di questa differenza mediante un test di Mann–Whitney, che ha restituito un p-value molto inferiore a 0.05, confermando che le due distribuzioni non sono compatibili.
Il fatto che l'autocorrelazione reale sia più negativa rispetto a quella simulata suggerisce un fenomeno di alternanza (anti-persistenza): nelle partite reali, dopo un successo, è leggermente più probabile osservare un insuccesso, e viceversa.

Probabilità media	45.34%
Lunghezza media	84.79
Lunghezza minima	60
Lunghezza massima	298

Tabella 1: Riassunto delle statistiche sulle sequenze dai dati reali

4.2 Pesi intrinseci dei diversi tiri

Una seconda domanda a cui ho cercato di rispondere è se i punti assegnati ai diversi tipi di tiri avessero lo stesso impatto sulla partita.
Il valore atteso è stato calcolato come:

$$Valore\ Atteso = P_{successo} \cdot Punti\ Assegnati$$

Questa misura permette di confrontare direttamente l'efficacia media dei diversi tiri, tenendo conto sia della difficoltà (probabilità di successo) sia della ricompensa (punti ottenuti).

Dal grafico in figura 2, si vede come il valore effettivo dei tiri sia inferiore a quello nominale, e che generalmente tenda a diminuire nel corso della partita.
I valori attesi medi sono:
- tiro da 2: 0.701
- tiro da 3: 1.458
- tiro libero: 0.468

4.3 Modello predittivo

L'obiettivo finale di questa analisi è stato quello di costruire un modello in grado di predire l'esito delle partite sulla base dei parametri stimati da stagioni precedenti.

Come descritto nella sezione 3.3, ho ipotizzato che ogni squadra possieda una probabilità intrinseca di successo p_i che ne rappresenta l'efficacia offensiva. Utilizzando i dati delle stagioni regolari dal 2014-2015 al 2017-2018, ho stimato questi parametri tramite massimizzazione della verosimiglianza, ottenendo così un vettore di probabilità per ogni squadra.

Assumendo indipendenza tra le azioni, la probabilità che una squadra A vinca contro una squadra B è modellata come:

$$P(A\ vince) = \frac{p_A(1-p_B)}{p_A(1-p_B)+p_B(1-p_A)}$$

Questa formula è derivata considerando le probabilità relative di successo per le due squadre durante una sequenza di azioni.
Utilizzando i parametri p stimati sulle stagioni 2014–2018, ho applicato il modello per predire l'esito delle partite della stagione 2018–2019, confrontando la squadra con probabilità maggiore con l'effettivo vincitore della partita.

Il modello ha raggiunto un'accuratezza del 57.56% sulle partite della stagione 2018–2019. Questo risultato indica che, pur trattandosi di un modello estremamente semplificato (non tiene conto di fattori contestuali, come infortuni, vantaggio del campo, o stato di forma), la stima di parametri intrinseci storici delle squadre può fornire una buona base per effettuare previsioni sull'esito delle partite.

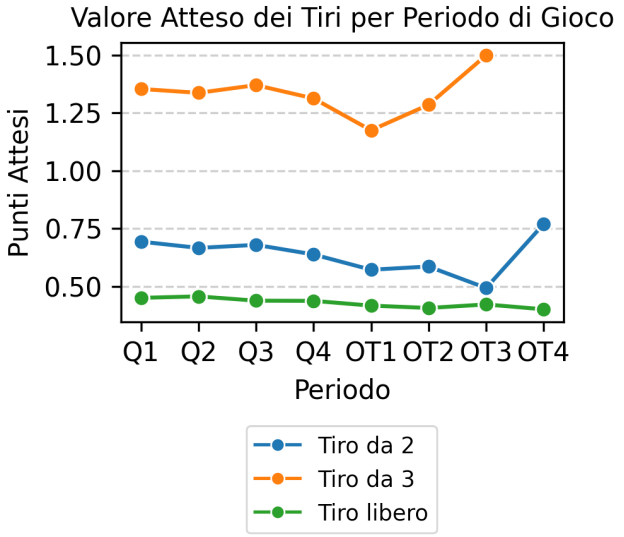


Figura 2: Andamento del valore reale medio dei punteggi dei vari tiri per i quattro periodi (Q1, Q2, Q3, Q4) e gli eventuali supplementari (OT1, OT2, OT3, OT4)